

BasketballAnalysis

Big Data de la NBA con IA y modelos predictivos de *machine learning*

Pablo Díaz

10 de octubre de 2025

Índice general

Índice de figuras	II
Acrónimos	III
1. Introducción	1
2. Marco teórico	4
2.1. Posesiones y ritmo	4
2.2. Métricas de eficiencia	4
2.3. Cuatro factores	5
2.4. On/Off y RAPM	5
2.5. Modelos predictivos para W/L	5
2.6. Buenas prácticas de datos	5
3. Datos	7
4. Metodología	8
5. Modelos predictivos (Estimadores)	9
5.1. Estimador 1: W/L por partido	9
5.2. Estimador 2: [TÍTULO DEL ESTIMADOR]	13
5.3. Estimador 3: [TÍTULO DEL ESTIMADOR]	14
6. Conclusiones y trabajo futuro	15

Índice de figuras

Acrónimos

- **NBA** — National Basketball Association
- **IA** — Inteligencia Artificial
- **ML** — *Machine Learning*
- **EDA** — *Exploratory Data Analysis*
- **API** — *Application Programming Interface*
- **ETL** — Extract, Transform, Load
- **eFG %** — *Effective Field Goal Percentage*
- **TS %** — *True Shooting Percentage*
- **ORtg** — *Offensive Rating*
- **DRtg** — *Defensive Rating*
- **NetRtg** — Net Rating
- **PACE** — Ritmo (posesiones por 48 min)
- **RAPM** — *Regularized Adjusted Plus-Minus*
- **RF** — *Random Forest*
- **XGBoost** — *Extreme Gradient Boosting*
- **ROC** — *Receiver Operating Characteristic*
- **AUC** — Área bajo la curva ROC
- **RMSE** — Raíz del Error Cuadrático Medio

- **MAE** — Error Absoluto Medio
- **SHAP** — *SHapley Additive exPlanations*
- **W/L** — *Win/Loss*

Capítulo 1

Introducción

BasketballAnalysis es un proyecto orientado a aplicar técnicas modernas de ia y ml sobre grandes volúmenes de datos de la nba. El objetivo es construir un flujo de trabajo reproducible que permita (i) entender qué factores explican el rendimiento de equipos, alineaciones y jugadores, y (ii) entrenar modelos predictivos capaces de estimar resultados wl y métricas asociadas al desempeño.

Motivación

La nba ofrece un ecosistema rico en datos: estadísticas tradicionales y avanzadas, *play-by-play*, información de contextos (local/visitante, descansos, parciales), e incluso datos derivados (on/off, alineaciones, clústeres de tiro). Aprovechar este *Big Data* con ia/ml permite pasar de la descripción a la predicción, optimizando la toma de decisiones (rotaciones, emparejamientos, recursos) y generando conocimiento accionable.

Problema a resolver

Dado un conjunto heterogéneo de fuentes (dashboards de equipo, alineaciones, tiro, pase, rebote, on/off, etc.), se requiere:

1. Integrar, limpiar y estandarizar tablas para un modelo de datos coherente.
2. Definir y calcular métricas clave (efg, ts, ortg, drtg, netrtg, pace) y derivadas contextuales (descanso, rachas, calendario).

3. Identificar *drivers* del rendimiento (correlaciones, importancia de variables, análisis de sensibilidad).
4. Entrenar y evaluar modelos predictivos para resultados wl y otros objetivos (p. ej. diferencial de puntos).

Objetivos específicos

- Diseñar un pipeline reproducible de etl y eda sobre datos de la nba.
- Construir y validar modelos de clasificación (p. ej. rf, xgb) para predicción wl.
- Evaluar modelos con métricas robustas (auc, mae, rmse, calibración) y análisis de importancia/explicabilidad (shap).
- Documentar supuestos, limitaciones y recomendaciones de uso.

Alcance

El documento cubre la cadena completa, desde la descripción de datos y métricas, hasta la preparación de *features*, *modeling* y evaluación. No se busca sustituir la *scouting* cualitativa, sino complementarla con evidencia cuantitativa.

Resumen metodológico

El flujo propuesto:

1. **Ingesta & limpieza:** carga de *parquet*, normalización de columnas y llaves (p. ej. *GAME_ID*, *TEAM_ID*).
2. **Ingeniería de variables:** métricas avanzadas, contexto (local/visitante, descansos, post-*All-Star*), *rolling windows*, *on/off*, alineaciones.
3. **EDA:** correlaciones (Spearman), mapas de calor, *feature screening*.
4. **Modelado:** rf/xgb con validación temporal, cuidado del *leakage*, balanceo si procede.
5. **Evaluación:** auc, mae/rmse (si regresión), curva roc, calibración y shap.

Organización del documento

El Capítulo 2 presenta el marco teórico; el Capítulo 3 describe los datos; el Capítulo ?? detalla el pipeline de preparación y modelado; el Capítulo ?? muestra resultados y visualizaciones; y el Capítulo ?? cierra con conclusiones y líneas futuras.

Capítulo 2

Marco teórico

Este capítulo establece los fundamentos conceptuales necesarios para el proyecto *BasketballAnalysis*. Primero se describen conceptos clave del baloncesto cuantitativo (posesiones, eficiencia, cuatro factores, alineaciones y contexto competitivo). Después, se presenta el armazón de aprendizaje automático empleado, incluyendo formulación del problema, validación temporal, modelos elegidos y consideraciones de calibración e interpretabilidad.

2.1. Baloncesto: fundamentos y métricas

Posesiones y ritmo

El análisis comparativo exige normalizar por volumen de posesiones. Una aproximación habitual al conteo de posesiones de un equipo es:

$$\text{Poss} \approx \text{FGA} + 0,44 \text{FTA} - \text{OREB} + \text{TOV}. \quad (2.1)$$

El **ritmo** o **PACE** expresa posesiones por 48 minutos y permite comparar equipos que juegan a velocidades distintas.

Eficiencia de tiro

La **eFG %** ajusta el valor del triple:

$$\text{eFG \%} = \frac{\text{FGM} + 0,5 \cdot \text{FG3M}}{\text{FGA}}. \quad (2.2)$$

La **TS %** aproxima la eficiencia de anotación global incorporando tiros libres:

$$\text{TS \%} = \frac{\text{PTS}}{2 (\text{FGA} + 0,44 \text{FTA})}. \quad (2.3)$$

Ratings por 100 posesiones

$$\text{ORtg} = 100 \cdot \frac{\text{PTS}}{\text{Poss}}, \quad \text{DRtg} = 100 \cdot \frac{\text{PTS concedidos}}{\text{Poss}}, \quad \text{NetRtg} = \text{ORtg} - \text{DRtg}. \quad (2.4)$$

Estos indicadores permiten separar contribuciones ofensivas y defensivas normalizadas.

Cuatro factores

Según la descomposición clásica, el rendimiento ofensivo se resume en cuatro pilares: (i) eficacia de tiro (eFG %), (ii) pérdidas (TOV %), (iii) rebote ofensivo (OREB %) y (iv) tiros libres (FTr). Analizar su contribución relativa ayuda a explicar variaciones en *NetRtg* entre equipos, alineaciones y contextos.

Alineaciones, on/off y estabilidad

La composición de quintetos modula los espacios de tiro, la creación y la contención defensiva. Las métricas *on/off* estiman el impacto de un jugador comparando el rendimiento del equipo cuando está en pista frente a cuando no lo está. No obstante, requieren *shrinkage* o regularización por tamaño muestral para evitar conclusiones espurias. La **estabilidad de rotación** (varianza de quintetos utilizados) es una pista útil de consistencia táctica.

Contexto competitivo

El lugar del partido (local/visitante), los días de descanso, los *back-to-back* y el calendario reciente condicionan el rendimiento. Las segmentaciones temporales (meses, pre/post All-Star) capturan cambios de tendencia y ajustes de plantilla.

2.2. Modelos y aprendizaje automático

Formulación del problema

El proyecto incluye estimadores de distinta naturaleza. El **Estimador 1** se plantea como clasificación binaria (W/L por partido). Otros estimadores pueden formularse como regresión (diferencial de puntos) o agregación/proyección (victorias de temporada).

Representación de datos y prevención de *leakage*

Se construye una tabla de **partido–equipo**, donde cada fila representa un equipo en un partido dado. Todas las variables (*features*) se calculan usando únicamente información disponible *antes* del salto inicial. Se emplean diferencias simétricas frente al rival ($\text{Feature_Diff} = \text{Equipo} - \text{Rival}$) para centrar el modelo en ventajas relativas.

Validación temporal

La evaluación se realiza con **backtesting *walk-forward***: se entrena en el histórico hasta un punto temporal T y se valida en el intervalo $(T, T + \Delta]$. Este esquema respeta la causalidad y evita fugas de información propias de particiones aleatorias.

Modelos utilizados

Random Forest (RF). Bosque de árboles con *bagging*. Ventajas: robustez, poco *tuning* y buena línea base. Parámetros prácticos: número de árboles alto, profundidad moderada, tamaño mínimo de hoja suficiente para evitar sobreajuste.

XGBoost (XGB). *Gradient boosting* con regularización explícita. Capta no linealidades e interacciones de forma eficiente y suele optimizar métricas como LogLoss con buen sesgo-varianza. Parámetros clave: `learning_rate`, `max_depth`, `subsample`, `colsample_bytree`, `min_child_weight` y regularización L1/L2.

Ponderación temporal y calibración

Las observaciones más recientes se ponderan más (decaimiento exponencial por días). La salida probabilística se **calibra** (Platt o isotónica) para que los porcentajes predichos coincidan con frecuencias observadas, lo cual es crucial en toma de decisiones.

Interpretabilidad

Se emplean importancias por permutación y, en su caso, *SHAP values* para explicar contribuciones globales y locales. La interpretabilidad permite auditar el comportamiento del modelo y detectar variables espurias o inestables.

Despliegue y control de calidad

En producción, el flujo actualiza las *features* hasta la víspera, infiere para los partidos del día y genera reportes de rendimiento, calibración y deriva (cambios de distribución) para mantenimiento preventivo.

Capítulo 3

Datos

En este capítulo se describe el origen de los datos, esquema de campos y controles de calidad (duplicados, rangos, nulos).

Capítulo 4

Metodología

Se detallan pasos de limpieza, reglas de imputación, cálculo de métricas avanzadas y criterios para comparar lineups y jugadores.

Capítulo 5

Modelos predictivos (Estimadores)

Este capítulo describe la familia de estimadores que convivirán en el proyecto. El **Estimador 1** aborda la probabilidad de victoria por partido (W/L). Se dejan además dos plantillas extensibles para estimadores adicionales, de modo que el proyecto crezca de forma coherente y modular.

5.1. Visión general

Todos los estimadores comparten un **núcleo de datos** y criterios de calidad: (i) ingesta y normalización de fuentes (*dashboards*, alineaciones, on/off, tiro/pase/rebote), (ii) ingeniería de variables por bloques, (iii) prevención de *leakage*, (iv) validación temporal *walk-forward*, (v) calibración de salidas y (vi) reportes con explicabilidad.

5.2. Estimador 1: Victoria/Derrota por partido (W/L)

5.2.1. Objetivo y unidad de análisis

La unidad es **partido–equipo**. Para cada encuentro se generan dos registros (local y visitante). La variable objetivo es binaria: $y = 1$ si el equipo gana y $y = 0$ si pierde. El modelo produce una probabilidad `p_win` previa al salto inicial y, opcionalmente, una proyección de victorias a futuro.

5.2.2. Diseño de *features*: bloques y filosofía

Las *features* se organizan en bloques, cada una calculada *hasta la víspera* del partido y en variantes *rolling* (3/5/10 últimos partidos) y *season-to-date*. Se prioriza la **simetría** mediante diferencias frente al rival (Equipo - Rival) para capturar ventajas relativas.

Bloque A — Fortaleza base y forma *Off/Def/Net Rating* y *PACE*, junto con los **Cuatro Factores** (eFG %, TOV %, OREB %, FTr). Se incluyen tendencias (diferencias recientes o pendientes) para reflejar forma.

Bloque B — Perfil de tiro y contestación Distribuciones por zona (aro, pintura, media, esquinas, *above-the-break*), tipología (pull-up vs. catch&shoot) y contestación (distancia del defensor, tiempo de toque). Se construyen señales de **calidad esperada** (xEFG) y se contrasta con lo que el rival concede.

Bloque C — Rebote y segundas oportunidades *OREB %*, *DREB %*, cadenas de segundas oportunidades y, si está disponible, métricas de *hustle* (boxouts, balones sueltos).

Bloque D — Creación y pérdidas *Assist %*, asistencias potenciales y secundarias, pases por posesión, puntos creados por pase, *TOV %* (idealmente separando pérdidas en vivo/muertas), transición (% posesiones y puntos).

Bloque E — Tiros libres y disciplina *Free Throw Rate* a favor/en contra, *FT %* y balance de faltas (recibidas/cometidas).

Bloque F — Contexto y calendario Local/visitante, diferencia de descanso, *back-to-back*, tramos de 3 en 4 días y segmentaciones temporales (meses, pre/post All-Star).

Bloque G — Clutch con *shrinkage* *NetRtg*, eFG % y pérdidas en minutos clutch, regularizados fuertemente para evitar ruido por muestras pequeñas.

Bloque H — Alineaciones esperadas y disponibilidad Quinteto probable y rotación corta. *Net/Off/Def Rating* de esas combinaciones (season-to-date y *rolling*) ponderados por minutos. *On/Off* de piezas clave con penalización por tamaño muestral. Estabilidad de rotación (varianza de quintetos utilizados recientemente).

Bloque I — Matchups estilísticos Compatibilidad entre lo que busca el ataque propio y lo que permite la defensa rival (rim attempts, corner 3, PnR handler, poste, etc. si están disponibles).

5.2.3. Construcción del dataset y control de calidad

1. Generar el calendario de partidos con identificadores (GAME_ID, fecha, local/visitante, equipos).
2. Para cada fecha, calcular todos los bloques hasta la víspera y cruzar contra el rival para obtener diferencias.
3. Etiquetar el resultado W/L para cada registro partido–equipo.
4. Imputar valores ausentes con estadísticas robustas (medianas por equipo o globales) y winsorizar *outliers*.
5. Asignar pesos temporales $w = \exp(-\Delta\text{días}/\text{halflife})$ (30–45 días como guía).

5.2.4. Validación y selección de modelos

El rendimiento se evalúa con **backtesting *walk-forward*** (entrenar hasta T , validar en $(T, T + \Delta]$). Métricas principales: *LogLoss*, *Brier score* y AUC, además de análisis de calibración (curvas de fiabilidad, ECE).

RF (línea base robusta). Árboles numerosos, profundidad moderada, hojas con tamaño mínimo generoso. Importancias por permutación en las ventanas de validación.

XGB (potencia y control). *Learning rate* bajo, *subsample* y *colsample* en rangos conservadores, *early stopping*. Regularización L1/L2 y *min_child_weight* para limitar complejidad efectiva.

Ensemble y calibración. Combinación ponderada de RF y XGB (según *LogLoss* en validación) o *stacking* con una logística final entrenada sobre predicciones *out-of-fold*. Calibración posterior (Platt o isotónica) en el último tramo de validación.

5.2.5. Producción y reportes operativos

- Actualizar diariamente las *features* hasta la víspera y obtener `p_win` de los partidos del día.
- Proyección de temporada: suma de probabilidades o simulación Monte Carlo sobre el calendario restante.
- Paneles de control: estabilidad mensual, sesgos local/visitante, bins de probabilidad vs. frecuencia real (calibración).
- Auditoría: importancias por permutación y *SHAP* (si se usa XGB) a nivel global y por partido.

5.2.6. Checklist mínimo viable (MVP)

- Núcleo: `NetRtg_diff`, `eFG%_diff`, `TOV%_diff`, `OREB%_diff`, `FTr_diff`.
- Apoyo: `3PA rate diff`, `rim attempt diff`, `opp rim FG% allowed diff`.
- Contexto: `Rest_diff`, `home`, flags de *back-to-back*.
- Plus: `Clutch_NetRtg_diff` regularizado y `Lineup_expected_NetRtg_diff`.

5.3. Estimador 2: Diferencial de puntos por partido

Objetivo (regresión). Predecir el diferencial de puntos final (`pts_for` - `pts_against`) en la unidad partido–equipo. Comparte bloques A–I del Estimador 1, pero el **target** es continuo. Se evalúa con RMSE/MAE y se vigila la calibración *quantile* (residuos simétricos).

Modelos. RF regresión (línea base) y XGB regresión (ajustando `max_depth`, `learning_rate`, regularización). Atención al **sesgo local/visitante** y a la **heterocedasticidad**: puede añadirse un modelo de varianza condicional o transformar el target (p.ej., winsorizar).

Uso. Este estimador alimenta pronósticos derivados (márgenes, *spreads*) y explica de forma continua el grado de superioridad/inferioridad esperado.

5.4. Estimador 3: Proyección de victorias de temporada

Objetivo (agregación/simulación). Convertir probabilidades partido a partido en **victorias esperadas** o en distribuciones de victorias mediante **Monte Carlo**.

Flujo. Usar las **p_win** del Estimador 1 a lo largo del calendario restante; (1) sumar probabilidades para una expectativa puntual, y/o (2) simular N trayectorias de temporada para obtener percentiles (P10/P50/P90).

Control. Recalibrar periódicamente **p_win** con resultados recientes, monitorizar deriva por cambios de plantilla y documentar supuestos (lesiones, descansos, traspasos).

5.5. Cierre

Este conjunto de estimadores cubre predicción binaria (W/L), magnitud del resultado (diferencial) y objetivos de planificación (victorias de temporada). La modularidad facilita añadir variantes (p.ej., *in-game live*, métricas por alineación, o *player impact*) sin reescribir el armazón.

Capítulo 6

Conclusiones y trabajo futuro

Resumen de aprendizajes clave, limitaciones y siguientes pasos (mejoras de datos, nuevos modelos, dashboards, etc.).